

MAT02034 – Métodos Bayesianos para Análise de Dados

Lista 1 - Revisão Inferência Bayesiana

Rafaela Oliveira

Agosto, 2025

Exercício 1. Quais são as principais diferenças entre a Inferência Clássica e a Inferência Bayesiana?

Exercício 2. Explique com detalhes uma vantagem da abordagem Bayesiana em comparação à abordagem Frequentista.

Exercício 3. Em relação aos diferentes tipos de distribuições *a priori*:

- a) O que é uma *a priori* subjetiva?
- b) O que é uma *a priori* conjugada?
- c) Qual a diferença entre uma *a priori* não-informativa e informativa?
- d) Qual a diferença entre uma *a priori* imprópria e própria?

Exercício 4. Em média, gêmeos fraternos ocorrem uma vez a cada 125 nascimentos e gêmeos idênticos uma vez a cada 300 nascimentos. Se Maria tem uma irmã gêmea, qual é a probabilidade de que Maria seja uma gêmea idêntica?

Dica 1: Considere que nascimentos de meninos e meninas possuem a mesma probabilidade.

Dica 2: Eventos – G = {Irmãs Gêmeas}, I = {Gêmeos Idênticos}, F = {Gêmeos Fraternos}.

Exercício 5. Identifique os núcleos das seguintes distribuições de probabilidade:

- a) Núcleo da $N(\mu, \sigma^2)$.
- b) Núcleo da Beta(α, β).
- c) Núcleo da Gama(α, β).
- d) Núcleo da Poisson(λ).

Exercício 6. Sejam X_i variáveis aleatórias iid, $i = 1, \dots, n$, com distribuição Poisson(λ), tal que o parâmetro λ é assumido com uma distribuição *a priori* Gama(a, b), com hiperparâmetros a e b conhecidos.

- a) Encontre a distribuição *a posteriori*.
- b) Encontre a média, a moda e a variância da *a posteriori*.
- c) Derive a preditiva *a posteriori* para uma observação futura.

Exercício 7. Sejam X_i variáveis aleatórias iid, $i = 1, \dots, n$, com distribuição Exp(λ), tal que o parâmetro λ é assumido com uma distribuição *a priori* Gama(a, b), com hiperparâmetros a e b conhecidos.

- a) Encontre a distribuição *a posteriori*.
- b) Encontre a média, a moda e a variância da *a posteriori*.
- c) Derive a preditiva *a posteriori* para uma observação futura.

Exercício 8. Sejam X_i variáveis aleatórias iid, $i = 1, \dots, n$, com distribuição $N(\mu, \sigma^2)$ com variância conhecida, tal que o parâmetro μ é assumido com uma distribuição *a priori* $N(\mu_0, \sigma_0^2)$, hiperparâmetros μ_0 e σ_0^2 conhecidos.

- a) Encontre a distribuição *a posteriori*.
- b) Encontre a média e a variância da *a posteriori*.
- c) O que acontece com *a posteriori* se $n \rightarrow \infty$?
- d) O que acontece com *a posteriori* se $\sigma_0^2 \rightarrow \infty$?

Exercício 9. Sejam X_i variáveis aleatórias iid, $i = 1, \dots, n$, com distribuição Weibull(λ, k).

Caso 1: O parâmetro λ é conhecido e o parâmetro k possui uma distribuição *a priori* Gama-Inversa(α, β), com hiperparâmetros α e β conhecidos.

Caso 2: O parâmetro k é conhecido e o parâmetro λ possui uma distribuição *a priori* Gama-Inversa(α, β), com hiperparâmetros α e β conhecidos.

- a) Encontre a distribuição *a posteriori* para cada um dos casos.
- b) Encontre a média, a moda e a variância da *a posteriori* para cada um dos casos.
- c) Derive a preditiva *a posteriori* para uma observação futura para cada um dos casos.

Resolução da lista 1

Grupo:

Davi Augusto;
Eduardo Garcez;
Gabriel Netto;
João Vitor Arend;
Luan Frederico.

Métodos Bayesianos - Lista 1

① Diferenças Inferência Clássica x Bayesianas:

Clássicas: Parâmetros são valores fixos desconhecidos.
não são r.p., portanto não fazemos declarações sobre suas
probabilidades.

Desconsiderar conhecimento prévio.

Uso da verossimilhança como base.

Bayesianas: Parâmetros são r.p.s + têm prob. associadas.

Usar "crencas" (a-priori) combinadas com a
verossimilhança para obter a posterior (atribuição
associada ao parâmetro de interesse).

— — — ② Vantagens da abordagem Bayesianas:

Interpretação direta do parâmetro \rightarrow Temos sua distribuição
a posteriori.

Exemplo:

Bayes \rightarrow "Há 95% de chance de θ estar no intervalo (A, B)"

freq \rightarrow "Com a repetição infinita do experimento
95% dos intervalos de confiança conteriam θ "

Per: Em Bayesianismo não temos intervalo de confiança mas
sim intervalo de credibilidade.

② a) a priori subjetiva:

Distribuições de probabilidade que expressam as crenças/conhecimentos prévio geralmente de um especialista.

b) a priori conjugada:

"Uma distribuição a priori é conjugada para serem funções de Jeoss. se a posterior resultante pertencer à mesma família da a priori."

c) Diferença entre informativa e não-informativa

Informativa: projetadas para refletir na a posteriori informações prévias sobre o parâmetro de interesse, geralmente variâncias pequenas e concentradas em certos valores + prováveis.

Não Informativa: seu impacto mínimo na posteriori.

d) Própria: uma densidade $p(\theta)$ é própria se em todo domínio de θ , $\int p(\theta) = 1$, caso as integrais sejam finitas + pode ser normalizada para se tornar própria.

Imprópria: se $\int p(\theta)$ não integrar em valor finito então é imprópria.

Queremos:

Temos:

$$\textcircled{4} \quad P(I|G) = \frac{P(G|I) \cdot P(I)}{P(G)}$$

$$P(I) = 1/200, P(F) = 1/125$$

$P(G|I)$ → serem duas irmãs dado que são idênticas.

$$\therefore P(G|I) = 1/2$$

$P(G|F)$ → serem irmãos | são fraternos. $P(G|F) = 1/4$

Prob. Total: Dois nascimentos de gêmeos → 2 meninos

$$P(G) = P(G|I) \cdot P(I) + P(G|F) \cdot P(F) = 0.0026$$

$$\therefore P(I|G) = \frac{1/2 \cdot 1/200}{0.0026} \approx \underline{\underline{0.15}}$$

A probabilidade é de 0.15.

Exercício 5 → Bayesian

a) Núcleo Normal $\$ N(\mu, \sigma^2)$

O núcleo de $N(\mu, \sigma^2)$ é ~~é só~~ fdp

$$f(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

b) Núcleo de Beta (α, β)

fdp da Beta

$$f(x|\alpha, \beta) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1} (1-x)^{\beta-1}$$

A → constante不影响 outcome da amostra

A → constante

B → Esse é o núcleo! parte funcional

B → Núcleo = $x^{\alpha-1} (1-x)^{\beta-1}$

que depende de x e da a distribuição
de forma de sino

c) Núcleo Gamma (α, β)

$$\text{fdp: } f(x|\alpha, \beta) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}$$

A → constante

$\Gamma(\alpha)$

B → Núcleo

d) Núcleo Poisson (λ)

fdp + mp → é discreta, então não é fdp

$$P(X=k|\lambda) = \frac{\lambda^k e^{-\lambda}}{k!}$$

A → núcleo

B → Constante

Ob

G Exercício 6) X_1, \dots, X_n iid com dist Poisson(λ) tal que λ é a priori Gamma(a, b) com hiper parâmetros a, b conhecidos

a) $P(\lambda | \text{dados})$ Encontrar posterior, ou seja $P(\lambda | \text{dados}) \propto P(\text{dados} | \lambda) \cdot P(\lambda)$ → núcleo a priori

com λ é nosso variável a substituimos no núcleo de Gamma $\Rightarrow P(\lambda) \propto \lambda^{a-1} e^{-b\lambda}$
 $\therefore P(X_i = x_i | \lambda) = \lambda^{x_i} e^{-\lambda}$ pois nossos dados (X_1, \dots, X_n) vem de uma Poisson(λ)
 \Rightarrow prob de uma unica obs $\neq x_i$

$P(\lambda | \text{dados}) \rightarrow$ multiplicar isso para todos os observações
verossimilhança $\rightarrow P(\text{dados} | \lambda) = \prod_{i=1}^n \frac{\lambda^{x_i} e^{-\lambda}}{x_i!} = \frac{\lambda^{\sum x_i} e^{-n\lambda}}{\prod_{i=1}^n x_i!} \rightarrow$ constante não depende de λ

$\therefore P(\text{dados} | \lambda) \propto \lambda^{\sum x_i} e^{-n\lambda} \rightarrow$ "receita verossimilhança" multiplicar o núcleo da priori

de verossimilhança

$$\therefore P(\lambda | \text{dados}) \propto P(\lambda) \cdot P(\text{dados} | \lambda) \Rightarrow P(\lambda | \text{dados}) \propto (\lambda^{a-1} e^{-b\lambda}) \times (\lambda^{\sum x_i} e^{-n\lambda}) \\ = P(\lambda | \text{dados}) \propto \lambda^{a+\sum x_i - 1} e^{-(b+n)\lambda} \rightarrow$$

similar ao núcleo da Gamma!

Portanto da priori Gamma e terminaremos com um núcleo que tem Gamma e a priori conjugada a forma Gamma! (Distribuição a posteriori também é Gamma) - Gamma é a priori conjugada da Poisson

Portanto Gamma ($a + \sum x_i, b + n$) é a nossa posteriori //

Obs: Os primeiros $\alpha \beta$ vem da expressão $\int \lambda^{a+\sum x_i - 1} e^{-(b+n)\lambda} d\lambda \rightarrow$ isso é da letra C!
des integral de fdp sobre o domínio $\alpha = 1$
 \hookrightarrow núcleo de uma Gamma.

b) média, moda e variância da posterior.

$$\rightarrow \text{média} = \alpha / \beta$$

$$\text{priori} \rightarrow \text{moda} = (\alpha - 1) / \beta, \text{ se } \alpha > 1$$

$$\hookrightarrow \text{var} = \alpha / \beta^2$$

$$\rightarrow \text{média} = \frac{\alpha + \sum x_i}{\beta + n}$$

$$\rightarrow \text{moda} = \frac{\alpha + \sum x_i - 1}{\beta + n}$$

$$\hookrightarrow \text{variância} = \frac{\alpha + \sum x_i - 1}{(\beta + n)^2}$$

c) Ideia \rightarrow com crença atualizada para λ , como podemos usar para prever uma nova observação \tilde{x} ? A distribuição a posteriori para esse pergunta é

$$P(\tilde{x} | \text{dados}) = \int P(\tilde{x} | \lambda) \times P(\lambda | \text{dados}) d\lambda \rightarrow \text{Nossa crença atualizada de } \lambda \Rightarrow \text{Gama}(\alpha + \sum x_i, \beta + n)$$

(\Rightarrow essa mistura gama e Poisson é uma Binomial negativa)

\hookrightarrow A integral que mistura uma verossimilhança de Poiss com priori ou posterior

Então, como resposta, temos que a distribuição posterior para uma nova observação \tilde{x} é uma Binomial negativa. Como os parâmetros dessa distribuição derivados diretamente da posterior gama(α' , β')

$$\therefore \tilde{x} | \text{dados} \sim NB(r = \alpha' = \alpha + \sum x_i, p = \beta' = \frac{\beta + n}{\beta + n + 1}) \quad p = \beta' = \frac{\beta + n}{\beta + n + 1} \quad \text{Probabilidade de sucesso } p$$

Exercício 7) Distribuição a priori: Gamma(α, β)

$$\text{f.d. exponencial } p(x|\lambda) = \lambda e^{-\lambda x}$$

$$\text{verossimilhança: } P(\text{dados}|\lambda) = \prod_{i=1}^n x_i e^{-\lambda x_i} \propto x^n e^{-\lambda \sum x_i}$$

Encontrar núcleo da posterior:

$$P(\lambda | \text{dados}) \propto (\lambda^{\alpha-1} e^{-\lambda x}) \times (\lambda^n e^{-\lambda \sum x_i})$$

Simplificando:

$$P(\lambda | \text{dados}) \propto (\lambda^{n+\alpha-1} e^{-(b+\sum x_i)\lambda})$$

$$\rightarrow \text{A priori: } p(\lambda) \propto \lambda^{\alpha-1} e^{-\lambda b}$$

núcleo de uma Gamma!
Gamma é a priori: conjugada para a verossimilhança da exponencial

$\therefore \text{Gamma}(\alpha + n, b + \sum x_i)$ é a nossa posterior.

b)

$$\text{Prior (Gamma}(\alpha, \beta)) \rightarrow \frac{\alpha}{\beta} \text{ média}, \frac{\alpha-1}{\beta} \text{ moda}$$

$$\rightarrow \frac{\alpha}{\beta^2} \text{ variância}$$

$$\text{Posterior} \rightarrow \frac{\alpha+n}{b+\sum x_i} \text{ média}$$

$$\rightarrow \frac{\alpha+n-1}{b+\sum x_i} \text{ moda}$$

$$\rightarrow \left(\frac{\alpha+n}{b+\sum x_i} \right)^2 \text{ variância}$$

$$\text{c)} P(\bar{x} | \text{dados}) = \int_0^\infty p(\bar{x}|\lambda) \cdot P(\lambda | \text{dados}) d\lambda \Rightarrow P(\bar{x} | \text{dados}) = \int_0^\infty (\bar{x} e^{-\bar{x}\lambda}) \times \left(\frac{(\beta')^\alpha}{\Gamma(\alpha)} \lambda^{\alpha-1} e^{-\beta'\lambda} \right) d\lambda$$

na nossa posterior: $\alpha' = \alpha + n$ e $\beta' = b + \sum x_i$

Reorganizando a integral

$$P(\bar{x} | \text{dados}) = \frac{(\beta')^{\alpha'}}{\Gamma(\alpha')} \int_0^\infty (\bar{x} \times \lambda^{\alpha'-1}) \times (e^{-\bar{x}\lambda} \times e^{-\beta'\lambda}) d\lambda$$

$$= P(\bar{x} | \text{dados}) = \frac{(\beta')^{\alpha'}}{\Gamma(\alpha')} \int_0^\infty \lambda^{\alpha'-1} e^{-(\beta'+\bar{x})\lambda} d\lambda \rightarrow \text{como é o núcleo da Gamma}$$

Poderemos usar o "trique" propriedade do resultado

$$\int_0^\infty t^{\alpha-1} e^{-\beta t} dt = \frac{\Gamma(\alpha)}{\beta^\alpha}$$

$$\therefore P(\bar{x} | \text{dados}) = \frac{(\beta')^{\alpha'}}{\Gamma(\alpha')} \times \frac{\Gamma(\alpha'+1)}{(\beta'+\bar{x})^{\alpha'+1}}$$

→ distribuição

de cometer

OU Pareto tipo 2

$$\therefore \bar{x} | \text{dados} \sim \text{Lomax}(\alpha = \alpha + n, \beta = b + \sum x_i)$$

Resolução (g) Exercício 6

Exercício 8) Receita Buget

a) $p(\text{dados}) \propto p(\text{dados} | \mu) \cdot p(\mu)$

$$\text{A priori } \mu \sim N(\mu_0, \sigma_0^2) \rightarrow \text{núcleo } \frac{e^{-(\mu-\mu_0)^2}}{2\sigma_0^2} \propto p(\mu)$$

$$p(\text{dados} | \mu) \propto \prod_{i=1}^n e^{-\frac{(x_i - \mu)^2}{2\sigma^2}} \Rightarrow \exp \left(\sum_{i=1}^n -\frac{(x_i - \mu)^2}{2\sigma^2} \right) = \exp \left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right)$$

$$\therefore p(\mu | \text{dados}) \propto \exp \left(-\frac{(\mu - \mu_0)^2}{2\sigma_0^2} - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right) \therefore \mu \sim N(\mu_n, \sigma_n^2)$$

b) Variação posterior = precisão prior + precisão posterior.

$$\frac{1}{\sigma_n^2} = \frac{1}{\sigma_0^2} + \frac{n}{\sigma^2} \quad \therefore \sigma_n^2 = \left(\frac{1}{\sigma_0^2} + \frac{n}{\sigma^2} \right)^{-1}$$

média posterior:

$$\mu_n = \left(\frac{1}{\sigma_0^2} \right) \mu_0 + \left(\frac{n}{\sigma^2} \right) \bar{x} \quad \therefore \mu_n = \sigma_n^2 \left(\frac{\mu_0}{\sigma_0^2} + \frac{n\bar{x}}{\sigma^2} \right)$$

Precisão inversa da variação
é a soma das precisões da crença inicial
e da fornecida pelos dados.

Regras Bayesiana: a precisão da crença final é a soma das precisões da crença inicial e da fornecida pelos dados.

O médio ponderado entre
a média da crença inicial
e a média observada dos dados

$$\frac{1}{\sigma_0^2} + \frac{n}{\sigma^2}$$

c) Se $n \rightarrow \infty$ → precisão da variação $\sigma_n^2 = \left(\frac{1}{\sigma_0^2} + \frac{n}{\sigma^2} \right)^{-1}$ praticamente nula

analogamente nossa precisão vai para o infinito!

$$\text{seja } \frac{1}{\sigma_n^2} = \frac{1}{\sigma_0^2} + \frac{n}{\sigma^2} \rightarrow \infty$$

ou seja, a variação da nossa crença sobre μ se é 0.

Já em $\mu_n = \sigma_n^2 \left(\frac{\mu_0}{\sigma_0^2} + \frac{n\bar{x}}{\sigma^2} \right)$ converge mais rápido quando $n \rightarrow \infty$

Portanto o médio da posterior (μ_n) converge para a média amostral (\bar{x})

d) A consequência de $\sigma_n^2 \rightarrow \infty$ na variação

é $\frac{1}{\sigma_n^2} = 0 + \frac{n}{\sigma^2} = \frac{n}{\sigma^2}$ ou seja a variação da posterior σ_n^2 se torna $\frac{\sigma^2}{n}$. A incerteza da crença final vem apenas dos dados

jaí para a média

$$M_n = \frac{(0) M_0 + \left(\frac{n}{\sigma^2}\right) \bar{x}}{0 + \frac{n}{\sigma^2}} = \frac{\left(\frac{n}{\sigma^2}\right) \bar{x}}{\left(\frac{n}{\sigma^2}\right)} = \bar{x}$$

A média de posterior: (M_n) converge para a média amostral

Exercício 9

a) Cuso 1:

Passo 1) verossimilhança

$$\text{PDF Weibull} = p(x_i | \kappa, \lambda) = \kappa \lambda x_i^{\kappa-1} e^{-\lambda x_i^\kappa}$$

$$\text{Verossimilhança} = \prod_{i=1}^n \kappa \lambda x_i^{\kappa-1} e^{-\lambda x_i^\kappa} \xrightarrow[\text{fazendo o que é parte de } \lambda \text{ depende de } \kappa]{} P(\text{dados} | \kappa) \propto \kappa^n (\prod x_i) ^{\kappa-1} e^{-\lambda \sum x_i^\kappa}$$

Passo 2) A priori \rightarrow Gamma-inversa (α, β)

$$\text{Núcleo dessa distribuição} \propto p(x_i) \propto x_i^{-(\alpha+1)} e^{-\beta/x_i}$$

Passo 3) A posteriori:

$$P(\kappa | \text{dados}) \propto (P(\text{dados} | \kappa) \kappa^{\alpha-1} e^{-\beta/\kappa}) \times (\kappa^{-(\alpha+1)} e^{-\beta/\kappa})$$

$$\Rightarrow P(\kappa | \text{dados}) \propto \kappa^{\alpha-1} (\prod x_i)^{\kappa-1} e^{-(\lambda \sum x_i^\kappa + \beta/\kappa)}$$

Cuso 2)

O mesmo processo do cuso 1), porém agora com λ conhecido e κ parâmetro.

Repetindo o processo temos a seguinte verossimilhança:

$$P(\text{dados} | \kappa, \lambda) \propto \kappa^n \lambda^n (\prod x_i)^{\kappa-1} e^{-\lambda \sum x_i^\kappa}$$

como λ é constante podemos isolá-la em λ e obter o núcleo da verossimilhança tal que

$$P(\text{dados} | \lambda) \propto \lambda^n e^{-\lambda \sum x_i^\kappa}$$

Prior para λ gamma inversa (α, β) com núcleo:

$$p(\lambda) \propto \lambda^{-(\alpha+1)} e^{-\beta/\lambda}$$

\therefore Nossa posterior:

$$P(\lambda | \text{dados}) \propto (\lambda^n e^{-\lambda \sum x_i^\kappa}) \cdot (\lambda^{-(\alpha+1)} e^{-\beta/\lambda})$$

$$\Rightarrow P(\lambda | \text{dados}) \propto \lambda^{n-\alpha-1} e^{-(\lambda \sum x_i^\kappa + \beta/\lambda)}$$

b) e c)

Ambos os curos para b) e c) não podem ser resolvidos a mão pois a posterior não é uma distribuição padrão.

Sendo assim não podemos encontrar a densidade preditiva, média, moda e variância do modo convencional.

Talvez seja possível computacionalmente.