

Métodos Bayesianos - Lista 1

① Diferenças Inferência Clássica x Bayesiana:

Clássica: Parâmetros são valores fixos desconhecidos.
não são v.a., portanto não fazemos declarações sobre sua probabilidade.

Desconsidera conhecimento prévio.

Uso da verossimilhança como base.

Bayesiana: Parâmetros são v.a.s \rightarrow têm prob. associadas.
Usa "crenças" (a-priori) combinadas com a verossimilhança para obter a posteriori (distribuição associada ao parâmetro de interesse).

— " —

② Vantagem da abordagem Bayesiana:

Interpretação direta do parâmetro \rightarrow Temos sua distribuição a posteriori.

Exemplo:

Bayes \rightarrow "Há 95% de chance de θ estar no intervalo (A, B)"

freq \rightarrow "com a repetição infinita do experimento 95% dos intervalos de confiança conteriam θ "

Ps: Em Bayesiana não temos intervalo de confiança mas sim intervalo de credibilidade.

② a) a priori subjetiva:

Distribuição de probabilidade que expressa a crença/conhecimento prévio geralmente de um especialista.

b) a priori conjugada:

"Uma distribuição a priori é conjugada para uma função de veross. se a posteriori resultante pertencer a mesma família da a priori."

c) Diferença entre informativa e não-informativa

Informativa: Projetada para refletir na a posteriori informações prévias sobre o parâmetro de interesse, geralmente variância pequena e concentrada em certos valores + prováveis.

Não Informativa: Tem impacto mínimo na posteriori.

d) Própria: Uma densidade $p(\theta)$ é própria se em todo domínio de θ , $\int p(\theta) = 1$, caso o integral seja finito $\neq 1$ pode ser normalizada para se tornar própria.

Imprópria: se $\int p(\theta)$ não integra em valor finito então é imprópria.

Queremos:

$$\textcircled{4} \quad P(I|G) = \frac{P(G|I) \cdot P(I)}{P(G)}$$

Temos:

$$P(I) = 1/200, \quad P(F) = 1/125$$

$P(G|I)$ \rightarrow serem dois irmãos dado que são idênticos:

$$\therefore P(G|I) = 1/2$$

$P(G|F)$ \rightarrow serem irmãos | são fraternos. $P(G|F) = 1/4$

Prob. Total: Dado Nascimento de Gêmeos \rightarrow 2 meninas

$$P(G) = P(G|I) \cdot P(I) + P(G|F) \cdot P(F) = 0.0036$$

$$\therefore P(I|G) = \frac{1/2 \cdot 1/200}{0.0036} \approx \underline{\underline{0.45}}$$

A probabilidade é de 0.45.

Exercício 5 → Bayesian

a) Núcleo Normal $N(\mu, \sigma^2)$

O núcleo de $N(\mu, \sigma^2)$ é $\frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$

$$f(x|\mu, \sigma^2) = \underbrace{\frac{1}{\sqrt{2\pi\sigma^2}}}_A \underbrace{e^{-\frac{(x-\mu)^2}{2\sigma^2}}}_B \rightarrow \text{Núcleo}$$

A → constante (ajusta altura da curva)
B → Esse é o núcleo! parte funcional que depende de x e dá a distribuição a forma de sino

b) Núcleo de Beta (α, β)

f.d.p. da Beta:

$$f(x|\alpha, \beta) = \underbrace{\frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)}}_A \underbrace{x^{\alpha-1}(1-x)^{\beta-1}}_B$$

A → constante

B → Núcleo = $x^{\alpha-1}(1-x)^{\beta-1}$

c) Núcleo Gamma (α, β)

$$f(x|\alpha, \beta) = \underbrace{\frac{\beta^\alpha}{\Gamma(\alpha)}}_A \underbrace{x^{\alpha-1} e^{-\beta x}}_B$$

A → constante

B → Núcleo

d) Núcleo Poisson (λ)

f.d.p. \rightarrow discreta, entã não é f.d.p.

$$P(X=k|\lambda) = \frac{\lambda^k e^{-\lambda}}{k!}$$

A → núcleo

B → constante

Ob

Exercício 6) X_i v.a iid com dist Poisson (λ) tal que λ é a priori Gamma (a, b) com hiper parâmetros a, b conhecidos

a) P^{post} Encontre posterior, ou seja $P(\lambda | \text{dados}) \propto P(\text{dados} | \lambda) \cdot P(\lambda)$ \rightarrow núcleo a priori

como λ é nossa variável a substituímos no núcleo de Gamma $\because P(\lambda) \propto \lambda^{a-1} e^{-b\lambda}$
 $\because P(X_i = x_i | \lambda) = \frac{\lambda^{x_i} e^{-\lambda}}{x_i!}$ pois nossos dados (x_1, \dots, x_n) vem de uma Poisson (λ)
 \hookrightarrow prob de uma única obs x_i

$P^{verossimilhança}$ \rightarrow multiplicar isso para todos n observações
 $P(\text{dados} | \lambda) = \prod_{i=1}^n \frac{\lambda^{x_i} e^{-\lambda}}{x_i!} = \frac{\lambda^{\sum x_i} e^{-n\lambda}}{\prod_{i=1}^n x_i!}$ \rightarrow constante! não depende de λ

$\because P(\text{dados} | \lambda) \propto \lambda^{\sum x_i} e^{-n\lambda} \rightarrow$ "receita bugesiana" multiplicar o núcleo da priori

e o da verossimilhança
 $\because P(\lambda | \text{dados}) \propto P(\lambda) \cdot P(\text{dados} | \lambda) \Rightarrow P(\lambda | \text{dados}) \propto (\lambda^{a-1} e^{-b\lambda}) \times (\lambda^{\sum x_i} e^{-n\lambda})$
 $= P(\lambda | \text{dados}) \propto \lambda^{a + \sum x_i - 1} e^{-(b+n)\lambda} \rightarrow$ similar ao núcleo da Gamma!

Portanto da priori Gamma e terminamos com um núcleo que tem a forma Gamma! (distribuição a posteriori também é Gamma) - Gamma é a priori conjugada do Poisson

Portanto Gamma ($a + \sum x_i, b + n$) é a nossa posteriori //

Obs: Os parâmetros a, b vem da expressão $\int \lambda^{a-1} e^{-(b+\lambda)} d\lambda \rightarrow$ isso é da letra C!
 \hookrightarrow núcleo de uma gamma.
 Obs: integral de fdp sobre o domínio é 1

b) média, moda e variância da posteriori

→ média = α / β

priori → moda = $(\alpha - 1) / \beta$, se $\alpha > 1$

↳ var = α / β^2

→ média = $\frac{a + \sum x_i}{b + n}$

posteriori → moda = $\frac{a + \sum x_i - 1}{b + n}$

↳ variância = $\frac{a + \sum x_i - 1}{(b + n)^2}$

c) Ideia → com crença atualizada para λ , como podemos usar para prever uma nova observação \tilde{x} ? A distribuição a posteriori para essa pergunta é

$P(\tilde{x} | \text{dados}) = \int P(\tilde{x} | \lambda) \times P(\lambda | \text{dados}) d\lambda$ → Nossa crença atualizada de $\lambda \Rightarrow \text{Gamma}(a + \sum x_i, b + n)$

→ essa mistura gamma e Poisson é uma Binomial negativa

↳ A integral que mistura uma verossimilhança de Poiss com priori ou posteriori gamma

Então, como resposta, temos que a distribuição preditiva a posteriori para uma nova observação \tilde{x} é uma Binomial negativa. Como parâmetros dessa distribuição derivamos diretamente da posteriori gamma(α' , β')

° ° $\tilde{x} | \text{dados} \sim NB(r = \alpha' = a + \sum x_i, p = \beta' = \frac{b + n}{b + n + 1})$ Número de falhas (r) probabilidade de sucesso (p)

Exercício 7) Distribuição a priori: Gamma(a, b)

do exponencial $p(z|\lambda) = \lambda e^{-\lambda z}$

verossimilhança: $P(\text{dados}|\lambda) = \prod_{i=1}^n \lambda e^{-\lambda z_i} \propto \lambda^n e^{-\lambda \sum z_i}$

Encontrar núcleo da posterior:

$$P(\lambda|\text{dados}) \propto (\lambda^{a-1} e^{-b\lambda}) \times (\lambda^n e^{-\lambda \sum z_i})$$

Simplificando:

$$P(\lambda|\text{dados}) \propto (\lambda^{n+a-1} e^{-(b+\sum z_i)\lambda})$$

→ núcleo de uma Gamma!
Gamma é a priori adequada para a verossimilhança da exponencial

∴ Gamma($a+n$, $b+\sum z_i$) é a nossa posterior

b)

Priori (Gamma(α, β)) → $\frac{\alpha}{\beta}$ média
→ $\frac{(\alpha-1)}{\beta}$, se $\alpha > 1$ moda
→ $\frac{\alpha}{\beta^2}$ variância

Posteriori → $\frac{a+n}{b+\sum z_i}$ média
→ $\frac{a+n-1}{b+\sum z_i}$ moda
→ $\frac{a+n}{(b+\sum z_i)^2}$ variância

$$c) P(\bar{x}|\text{dados}) = \int_0^{\infty} p(\bar{x}|\lambda) \cdot P(\lambda|\text{dados}) d\lambda \Rightarrow P(\bar{x}|\text{dados}) = \int_0^{\infty} (\lambda e^{-\lambda \bar{x}}) \times \left(\frac{(\beta')^{\alpha'}}{\Gamma(\alpha')} \lambda^{\alpha'-1} e^{-\beta' \lambda} \right) d\lambda$$

na nossa posteriori $\alpha' = a+n$ e $\beta' = b + \sum z_i$

Reorganizando a integral

$$P(\bar{x}|\text{dados}) = \frac{(\beta')^{\alpha'}}{\Gamma(\alpha')} \int_0^{\infty} (\lambda \times \lambda^{\alpha'-1}) \times (e^{-\lambda \bar{x}} \times e^{-\beta' \lambda}) d\lambda$$

$$= P(\bar{x}|\text{dados}) = \frac{(\beta')^{\alpha'}}{\Gamma(\alpha')} \int_0^{\infty} \lambda^{\alpha'-1} e^{-(\beta'+\bar{x})\lambda} d\lambda$$

→ como é o núcleo da Gamma podemos usar o "truque" propriamente de o resultado

$$\int_0^{\infty} \lambda^{A-1} e^{-B\lambda} d\lambda = \frac{\Gamma(A)}{B^A}$$

$$\therefore P(\bar{x}|\text{dados}) = \frac{(\beta')^{\alpha'}}{\Gamma(\alpha')} \times \frac{\Gamma(\alpha'+1)}{(\beta'+\bar{x})^{\alpha'+1}} \quad \text{com } \mu(z+1) = z \Gamma(z)$$

$$= \frac{\alpha' (\beta')^{\alpha'}}{(\beta'+\bar{x})^{\alpha'+1}}$$

→ distribuição de Lomax ou Pareto tipo 2

∴ $\bar{x}|\text{dados} \sim \text{Lomax}(\alpha = a+n, \lambda = b + \sum z_i)$

Resolução © Exercício 6

Exercício 8) Receta Bayes

a)

$P(\text{dados})$ & $P(\text{dados} | \mu) + P(\mu)$
A priori $\mu \sim N(\mu_0, \sigma_0^2) \rightarrow$ núcleo $\frac{e^{-\frac{(\mu - \mu_0)^2}{2\sigma_0^2}}}{\sigma_0}$ $\propto P(\mu)$

$$P(\text{dados} | \mu) \propto \prod_{i=1}^n e^{-\frac{(x_i - \mu)^2}{2\sigma^2}} \Rightarrow \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right) = \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right)$$

$$\therefore P(\mu | \text{dados}) \propto \exp\left(-\frac{(\mu - \mu_0)^2}{2\sigma_0^2} - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right) \therefore \mu \sim N(\mu_n, \sigma_n^2)$$

b) Variância posteriori = precisão priori + precisão posteriori

$$\frac{1}{\sigma_n^2} = \frac{1}{\sigma_0^2} + \frac{n}{\sigma^2} \therefore \sigma_n^2 = \left(\frac{1}{\sigma_0^2} + \frac{n}{\sigma^2}\right)^{-1}$$

Precisão inverso da variância
Alta precisão baixa variância

média posteriori

$$\mu_n = \left(\frac{1}{\sigma_0^2}\right) \mu_0 + \left(\frac{n}{\sigma^2}\right) \bar{x} \therefore \mu_n = \sigma_n^2 \left(\frac{\mu_0}{\sigma_0^2} + \frac{n\bar{x}}{\sigma^2}\right)$$

Regra Bayesiana: a previsão da crença final é a soma das previsões da crença inicial e da fórmula vindo dos dados

$$\frac{1}{\sigma_0^2} + \frac{n}{\sigma^2}$$

é a média ponderada entre a média da crença inicial e a média dos dados

c) se $n \rightarrow \infty \rightarrow$ precisão
a variância $\sigma_n^2 = \left(\frac{1}{\sigma_0^2} + \frac{n}{\sigma^2}\right)^{-1}$ praticamente vai a 0

analogamente nossa precisão vai para o infinito

$$\text{veja } \frac{1}{\sigma_n^2} = \frac{1}{\sigma_0^2} + \frac{n}{\sigma^2} \rightarrow \infty$$

ou seja, a variância da nossa crença sobre μ vai a 0.

$$\text{já em } \mu_n = \sigma_n^2 \left(\frac{\mu_0}{\sigma_0^2} + \frac{n\bar{x}}{\sigma^2}\right) \rightarrow \text{converge mais rápido quando } \frac{n}{\sigma^2} \rightarrow \infty$$

Portanto a média da posteriori (μ_n) converge para a média amostral (\bar{x})

d) A consequência de $\sigma_0^2 \rightarrow \infty$ na variância

é $\frac{1}{\sigma_n^2} = 0 + \frac{n}{\sigma^2} = \frac{n}{\sigma^2}$ Ou seja a variância da posteriori σ_n^2 se torna $\frac{\sigma^2}{n}$. A incerteza da crença final vem apenas dos dados

já para a média

$$\mu_n = \frac{(0)\mu_0 + \left(\frac{n}{\sigma^2}\right)\bar{x}}{0 + \frac{n}{\sigma^2}} = \frac{\left(\frac{n}{\sigma^2}\right)\bar{x}}{\left(\frac{n}{\sigma^2}\right)} = \bar{x}$$

A média de posteriori (μ_n) converge para a média amostral

Exercício 9

a) Caso 1:

Passo 1) verossimilhança

$$\text{PDF Weibull} = P(x_i | \kappa, \lambda) = \kappa \lambda x_i^{\kappa-1} e^{-\lambda x_i^\kappa}$$

$$\text{Verossimilhança} = \prod_{i=1}^n \kappa \lambda x_i^{\kappa-1} e^{-\lambda x_i^\kappa}$$

o núcleo depende de κ

$$P(\text{dados} | \kappa) \propto \kappa^n (\prod x_i)^{\kappa-1} e^{-\lambda \sum x_i^\kappa}$$

Passo 2) A priori \rightarrow Gamma-Inversa (α, β)

$$\text{Núcleo dessa distribuição é } P(\kappa) \propto \kappa^{-(\alpha+1)} e^{-\beta/\kappa}$$

Passo 3) A posteriori

$$P(\kappa | \text{dados}) \propto (\kappa^n (\prod x_i)^{\kappa-1} e^{-\lambda \sum x_i^\kappa}) \times (\kappa^{-(\alpha+1)} e^{-\beta/\kappa})$$

$$\Rightarrow P(\kappa | \text{dados}) \propto \kappa^{n-\alpha-1} (\prod x_i)^{\kappa-1} e^{-(\lambda \sum x_i^\kappa + \beta/\kappa)}$$

Caso 2)

O mesmo processo do caso 1), porém agora com λ conhecido e κ parâmetro. Repetindo o processo temos a seguinte verossimilhança

$$P(\text{dados} | \kappa, \lambda) \propto \kappa^n \lambda^n (\prod x_i)^{\kappa-1} e^{-\lambda \sum x_i^\kappa}$$

como λ é constante podemos ignorar em λ e obter o núcleo da verossimilhança tal que

$$P(\text{dados} | \lambda) \propto \lambda^n e^{-\lambda \sum x_i^\kappa}$$

Priori para λ gamma inversa (α, β) com núcleo

$$P(\lambda) \propto \lambda^{-(\alpha+1)} e^{-\beta/\lambda}$$

\therefore Nossa posteriori

$$P(\lambda | \text{dados}) \propto (\lambda^n e^{-\lambda \sum x_i^\kappa}) \cdot (\lambda^{-(\alpha+1)} e^{-\beta/\lambda})$$

$$\Rightarrow P(\lambda | \text{dados}) \propto \lambda^{n-\alpha-1} e^{-(\lambda \sum x_i^\kappa + \beta/\lambda)}$$

b) e c)

Ambos os casos para b) e c) não podem ser resolvidos a mão pois a posteriori não é uma distribuição padrão

Sendo assim não podemos encontrar a densidade preditiva, média, moda e variância do modo convencional,

Talvez seja possível computacionalmente